CIFAR-10 图像分类

10245501412 贾舒羽

1 实验任务与评价协议

本实验在 CIFAR-10 上比较自定义 CNN、残差网络、SE 注意力、数据增强与迁移学习。从官方 50,000 张训练图像按类别分层抽取 5,000 张用于验证（每类 500 张），其余 45,000 张用于训练（每类 4,500 张）；另有 10,000 张官方测试图像。划分种子为 42，标准化参数只由训练子集计算。

按项目记录，初始 24 轮实验已评估测试集；延长至 72 轮是基于验证集表现和训练耗时作出的决定，未将测试准确率作为决策依据。训练中的最佳权重和最终模型均以验证准确率选择。权重衰减设为 0 的 24 轮对照是在正式主模型确定后补做。由于此前已有测试集评估，第三阶段的 Cutout 和预训练结果均作为探索性分析，正式主模型选择不变。正式主配置为窄通道 ResNet-18、基础增强、平滑 0.1、72 轮、种子 42。

2 模型结构与 SE 通道注意力

Custom CNN 由三组双 3×3 卷积构成，通道依次为 32、64、128；卷积后使用 BatchNorm 和 ReLU，每组后进行 2×2 最大池化，最后通过全局平均池化和全连接层输出十类。窄通道 CIFAR ResNet-18 使用 3×3、步长 1 的输入卷积并移除初始最大池化；四个阶段的通道为 16、32、64、128，每阶段两个 BasicBlock，特征图空间尺寸依次为 32、16、8、4。

残差块计算为 y = ReLU(F(x) + S(x))。空间尺寸或通道数变化时，捷径 S(x) 使用 1×1 投影匹配维度。SE 对每个通道做全局平均池化，再经两层映射得到激励权重 s = sigmoid(W_2 ReLU(W_1 z))，最后计算下式所示的通道重标定。压缩率 r=16；通道 16、32、64、128 对应隐藏维度 1、2、4、8。SE 位于第二个卷积的 BatchNorm 之后、残差相加之前。

$$z_c = \frac{1}{HW}\sum_{h=1}^{H}\sum_{w=1}^{W} x_c(h,w) \;;\; \tilde{x}_c = s_c \cdot x_c$$

符号说明：x 为输入特征；H、W 为空间高度和宽度；z_c 为第 c 通道的均值；s_c 为对应激励系数；F 为残差主支路，S 为捷径映射；W_1 、W_2 为全连接权重，r 为 SE 压缩率。

表 1　模型规模与计算量

模型	参数量	卷积与线性层 MACs/图像	结构说明
Custom CNN	288,746	38,634,752	三组双卷积
窄通道 ResNet-18	701,466	35,046,656	四阶段 BasicBlock
SE-ResNet-18	707,416	35,052,096	SE 压缩率 r=16

3 数据处理与训练设置

输入像素先除以 255，再使用训练集通道均值(0.4911, 0.4821, 0.4464)和标准差(0.2469, 0.2434, 0.2616)标准化。基础增强为补零 4 像素后的 32×32 随机裁剪和概率 0.5 的水平翻转。Cutout 在标准化后将随机 8×8 区域置 0，对应原始像素空间的各通道均值，并非在标准化之前填入 RGB 黑色。验证与测试使用确定性预处理。

表 2　主要训练配置

设置	从头训练 ResNet	ImageNet 预训练 ResNet-18
输入尺寸	32×32	224×224
批量大小	256	32
训练轮数	72	最多 12；patience=3
优化器	AdamW	AdamW
学习率	0.003	骨干 0.0001；分类头 0.001
调度策略	Cosine；eta_min=0.00005	Cosine；eta_min=0.000001
权重衰减	0.01	0.01
损失函数	交叉熵；label smoothing=0.1	交叉熵

关键代码片段：残差捷径、SE 模块与训练循环

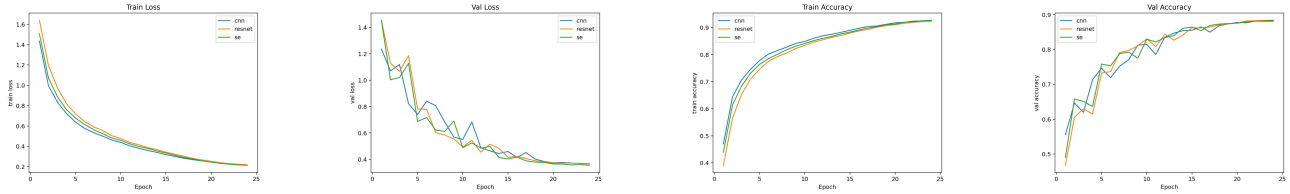
```
# torchvision BasicBlock 残差捷径（等价简写）
identity = x if self.downsample is None else self.downsample(x)
out = self.relu(out + identity)

# src/models.py：SE 模块
self.bn2 = nn.Sequential(self.bn2, SqueezeExcitation(planes, max(1, planes // 16)))
# src/models.py: CIFAR stem
self.conv1 = nn.Conv2d(3, 16, 3, padding=1, bias=False)
self.maxpool = nn.Identity()
```

```
# src/train.py：训练、验证与最佳权重更新
tr, _, _ = run_epoch(net, train, norm, batch, aug, opt, smoothing)
va, _, _ = run_epoch(net, val, norm, batch)
if not history or va[1] > max(r['val_accuracy'] for r in history):
    torch.save(net.state_dict(), folder / 'best.tmp')
    (folder / 'best.tmp').replace(folder / 'best.pt')
```

4 训练过程与初始结构、增强对照

以下四张训练曲线均直接取自项目 results/figures 文件夹，展示 24 轮基础增强、标签平滑 0、种子 42 下 CNN、ResNet 与 SE-ResNet 的训练和验证过程。图片内原有英文标题、图例、坐标轴和数据均未翻译、重绘或修改。



（a）训练损失　（b）验证损失　（c）训练准确率　（d）验证准确率

图 1　三种模型在 24 轮训练中的训练与验证曲线

三种模型的最佳验证准确率分别为 88.14%、88.40% 和 88.38%。训练损失整体下降，训练准确率整体上升；验证损失和验证准确率存在阶段性波动，但总体改善。该图对应基础增强、标签平滑 0、种子 42 的 24 轮实验；曲线用于描述训练动态，不单独证明模型具有稳定泛化优势，模型选择仍以各配置的验证集记录为准。

表 3　24 轮结构、增强、损失对照及后补权重衰减实验

对照类别	配置	最佳验证准确率	测试准确率
结构	Custom CNN	88.14%	86.95%
结构	窄通道 ResNet-18	88.40%	87.19%
结构	SE-ResNet-18	88.38%	87.47%
增强	无随机增强	83.46%	81.77%
增强	基础增强	88.40%	87.19%
增强	基础增强 + Cutout	87.62%	87.24%
损失	标签平滑 0.1	88.54%	87.55%
后补正则化	权重衰减 0（24 轮）	88.16%	87.73%

表 3 均采用 24 轮、种子 42；“基础增强”行即窄通道 ResNet-18、平滑 0、权重衰减 0.01 的对照基准。末行权重衰减 0 使用相同 24 轮配置，但在 72 轮正式模型确定后补充，不参与选模；24 轮结果也不应与 72 轮主模型直接比较。基础增强比无增强的测试准确率高 5.42 个百分点；24 轮 Cutout 仅高 0.05 个百分点、验证低 0.78 个百分点。SE 测试高 0.28 个百分点、验证低 0.02 个百分点；标签平滑 0.1 的测试高 0.36 个百分点；权重衰减 0 的测试高 0.54 个百分点而验证低 0.24 个百分点。

5 Basic 与 Cutout：72 轮三种子配对实验

两组均使用窄通道 ResNet-18、标签平滑 0.1、batch=256、AdamW、学习率 0.003、权重衰减 0.01 和 Cosine 调度；唯一改变因素为是否加入 8×8 Cutout。每个种子使用相同数据划分和训练预算。

表 4　Basic 与 Cutout 三种子配对结果（准确率，%）

种子	Basic 验证	Cutout 验证	Basic 测试	Cutout 测试	测试差值/pp
42	90.62%	90.44%	89.31%	90.16%	+0.85

种子	Basic 验证	Cutout 验证	Basic 测试	Cutout 测试	测试差值/pp
43	90.40%	91.00%	89.51%	90.12%	+0.61
44	90.40%	91.02%	89.65%	90.58%	+0.93
均值±样本 SD	90.47±0.13%	90.82±0.33%	89.49±0.17%	90.29±0.25%	+0.80

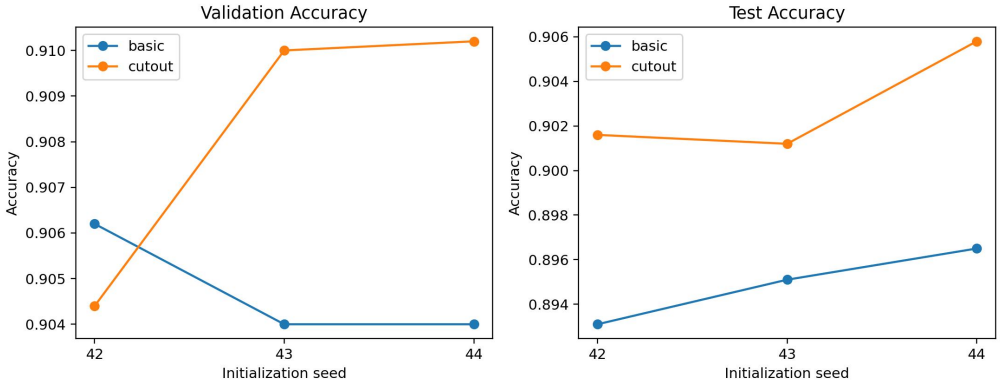


图 2　Basic 与 Cutout 三种子验证、测试准确率对照

72 轮配对对照中，Cutout 的验证准确率均值比 Basic 高 0.35 个百分点，测试均值高 0.80 个百分点，但种子 42 的验证差值为-0.18 个百分点。三个种子测试差值均为正；由于测试集此前已被查看，这属于探索性结果。训练含验证的平均耗时分别为 Basic 306.26s 与 Cutout 332.93s，增加 8.7%。

6 ImageNet 预训练迁移学习参照

采用 torchvision ResNet-18 的 ImageNet1K_V1 官方预训练权重，将分类头替换为十类。输入图像由 32×32 插值至 224×224。使用 ImageNet 均值和标准差。骨干学习率为 0.0001，分类头为 0.001，AdamW 权重衰减 0.01，最多训练 12 轮，patience=3，最佳验证轮次为第 11 轮。

表 5　迁移学习参照与从头训练模型对照（非公平对照）

模型	输入/预算	验证准确率	测试准确率	参数量	对照性质
ImageNet ResNet-18	224×224；最多 12 轮	96.68%	96.28%	11,181,642	非公平对照：预训练及高分辨率
窄通道 ResNet-18	32×32；72 轮	90.62%	89.31%	701,466	从头训练主模型

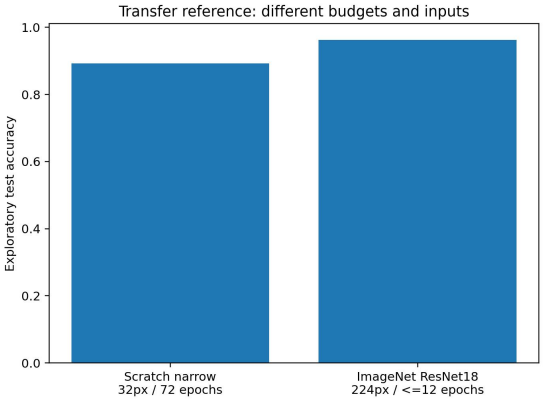


图 3　预训练迁移参照与从头训练模型的测试准确率

ImageNet 预训练 ResNet-18 的测试准确率比从头训练主模型高 6.97 个百分点。但预训练数据、输入尺寸（224×224 与 32×32）、参数量和训练预算均不同；该结果用于迁移学习性能参照，不能用于单独判断网络架构优劣。

7 混淆矩阵与误分类分析

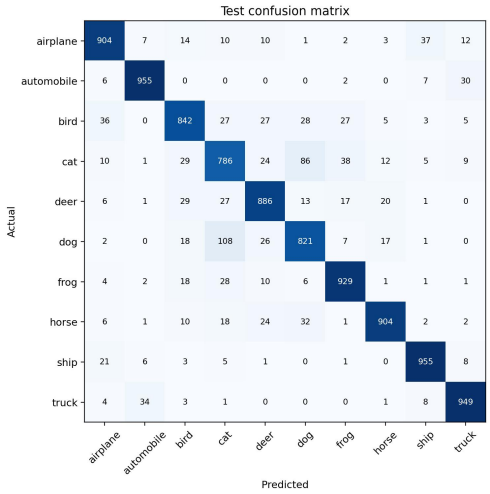


图 4　正式主模型测试集混淆矩阵

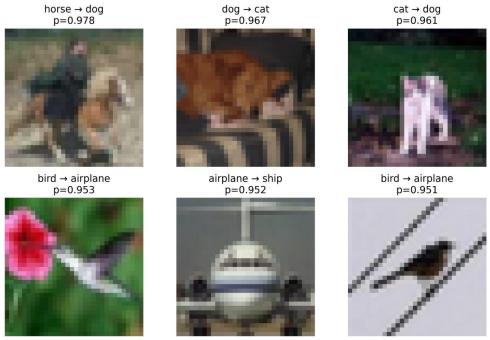


图 5　高置信度误分类样本（六例）

混淆矩阵按真实类别为行、预测类别为列。主要错误包括 dog→cat 108 张(10.8%)、cat→dog 86 张(8.6%)、cat→frog 38 张(3.8%)、airplane→ship 37 张(3.7%)和 bird→airplane 36 张(3.6%)，括号为占真实类别 1,000 张的比例。图 5 从全部错误预测中选取置信度最高的 6 例并按置信度降序排列，并非按错误类别均衡抽样。

表 6　各类别测试指标

类别	样本数	Precision/%	Recall/%	F1/%
airplane	1,000	90.5	90.4	90.4
automobile	1,000	94.8	95.5	95.2
bird	1,000	87.2	84.2	85.7
cat	1,000	77.8	78.6	78.2
deer	1,000	87.9	88.6	88.2
dog	1,000	83.2	82.1	82.6
frog	1,000	90.7	92.9	91.8
horse	1,000	93.9	90.4	92.1
ship	1,000	93.6	95.5	94.6
truck	1,000	93.4	94.9	94.1

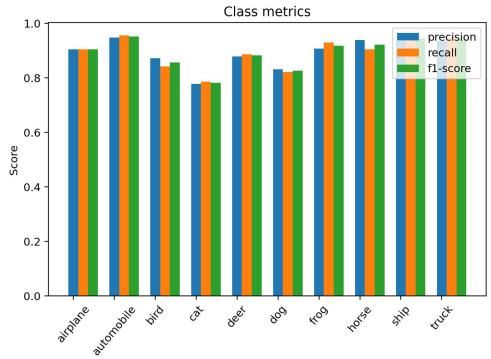


图 6　各类别 Precision、Recall 与 F1

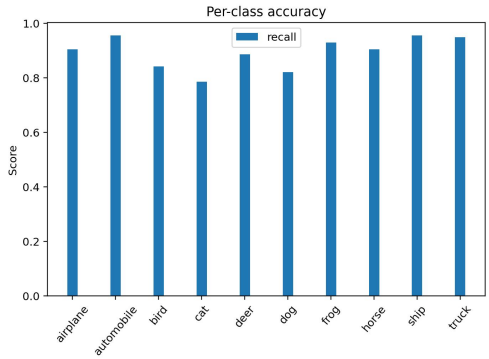


图 7　各类别 Recall（各类样本数相同）

正式主模型测试准确率为 89.31%。十类测试样本各 1,000 张，总准确率等于十类 Recall 的算术平均。cat 的 Recall 最低，为 78.6%；dog、bird 分别为 82.1%、84.2%；automobile 与 ship 的 Recall 均为 95.5%。Precision 衡量预测为该类时的正确比例，Recall 衡量该类被识别的比例，F1 为二者的调和平均。

8 Grad-CAM 可解释性分析

项目原始 Grad-CAM 图同时展示正确样本 0（cat）和错误样本 1884（horse→dog），见图 8。样本 1884 的预测置信度为 97.86%。图 9 进一步分别针对真实类别 horse 和预测类别 dog 的 logit 求梯度，得到双目标 Grad-CAM；末级 layer4 特征图仅 4×4，空间定位能力有限，热图反映较粗粒度的梯度相关性。

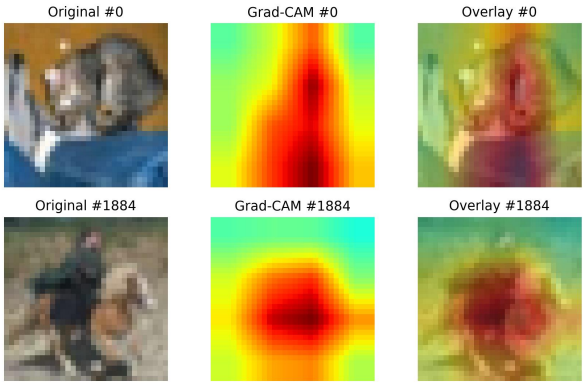


图 8　正确与错误样本的预测类别 Grad-CAM（原始实验图）

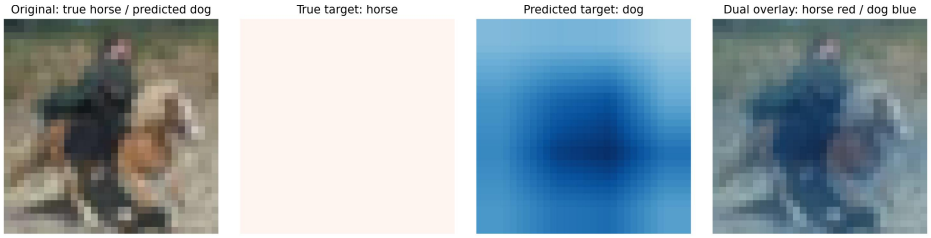


图 9　样本 1884 的双目标 Grad-CAM（horse 为真实类别，dog 为预测类别）

horse 目标热图经 ReLU 后全零，dog 目标热图存在非零响应并覆盖图像中央区域。全零图按实际结果保留，未人为归一化或补造热区；这表示当前 layer4 特征下未得到 horse 的正向 Grad-CAM 响应，不等于模型完全没有编码 horse 特征。Grad-CAM 反映梯度相关性，不构成因果解释。

9 计算效率与综合讨论

表 7　模型复杂度与前向延迟

模型	参数量	MACs/图像	128 张前向中位数/ms
Custom CNN	288,746	38.63M	1.786
ResNet	701,466	35.05M	5.570
SE-ResNet	707,416	35.05M	9.575

虽然 Custom CNN 的 MACs（38.63M）略高于 ResNet（35.05M），128 张批量前向中位数却更低（1.786ms 对 5.570ms）。一个可能原因是 CNN 仅有 6 个卷积层，而残差网络包含更多串行卷积、投影捷径与残差相加，算子启动和中间访存开销更高；本实验未做算子级 Profiler，故不把该解释视为定论。SE 相对 ResNet 的 MACs 仅增约 0.0155%，但前向延迟约为 1.72 倍；其 24 轮结构对照仅单种子，无法证明稳定精度收益。

10 结论、局限与复现

正式主模型为窄通道 ResNet-18（基础增强、平滑 0.1、72 轮、种子 42），测试准确率 89.31%；Basic 三种子均值为 89.49%±0.17%，Cutout 为 90.29%±0.25%，配对测试均值差+0.80 个百分点。第三阶段测试属于探索性比较。ImageNet 预训练参照达到 96.28%，体现迁移学习方案在不同训练条件下的表现。实验完成了架构、增强和优化对照以及 Grad-CAM 解释性分析，仍需更多种子和严格匹配预算的实验评估 SE 收益。

后续可在相同训练预算下进行 SE/ResNet 多种子配对、标签平滑×权重衰减交叉对照，并对 Cutout 使用新的独立数据作确认性评估。

实验共 16 组，其中原有 12 组，第三阶段新增 3 组 72 轮 Cutout 实验和 1 组 ImageNet 预训练实验。16 组实验各保存配置、最佳权重、训练历史、测试预测和分类指标，共 16 份最佳模型权重、80 份核心实验文件。results/figures/ 保存 15 张原始实验图表。